UNIVERSIDAD FRANCISCO DE VITORIA
Facultad de Derecho, Empresa y Gobierno
Grado en ADE y Business Analytics

ANÁLISIS DEL DATO

Comparativa de riesgo y rentabilidad entre banca tradicional y tech financiero (2015–2024)

Juan Lantero de la Osa
Trabajo de Fin de Grado
Curso 2025–2026

Índice

1. Introducción y contexto del análisis 3

2. Marco teórico y justificación metodológica 4

3. Modelo no supervisado I: Clustering Jerárquico 6

4. Modelo no supervisado II: Análisis de Componentes Principales (PCA) 8

5. Modelo supervisado: Árbol de Decisión 10

6. Análisis estadístico: Test de Mann-Whitney por subperiodo 12

7. Conclusiones del Análisis del Dato 15

8. Referencias bibliográficas 17

1. Introducción y contexto del análisis

Una vez completada la Ingeniería del Dato (que incluyó la obtención, limpieza y estructuración del dataset) este segundo pilar del trabajo aplica metodología analítica formal para dar respuesta empírica a la pregunta central de la investigación. El dataset de partida proviene de tres fuentes: precios históricos ajustados por dividendo de Yahoo Finance, el bono alemán a 10 años como tasa libre de riesgo obtenida de FRED (serie IRLTLT01DEM156N), y el EUROSTOXX 50 como benchmark de mercado obtenido de Investing.com. El output de la Ingeniería del Dato (el archivo DATOS_TFG_LIMPIO.xlsx, ya transformado y con todas las variables calculadas) es el input directo de este análisis.

Pregunta de investigación
¿Han ofrecido las empresas de tech financiero una mejor relación rentabilidad–riesgo que la banca tradicional entre 2015 y 2024?

El dataset recoge datos mensuales de diez empresas - cinco bancos tradicionales (BBVA, Santander, BNP Paribas, Deutsche Bank y HSBC) y cinco empresas de tech financiero (Fiserv Inc., Fidelity National Information Services Inc., Global Payments Inc., Intuit Inc. y Visa Inc.) - durante el periodo enero 2015 a diciembre 2024, lo que supone 1.200 observaciones en total. El dataset final contiene 20 columnas, sin valores nulos en las variables de precio y rentabilidad, y con 110 nulos esperados en Sharpe ratio, Beta, Alpha y Volatilidad mensual correspondientes a los primeros 11 meses de cada empresa — resultado natural de la ventana rolling de 12 meses aplicada en su cálculo.

El análisis se estructura en cuatro niveles complementarios, cada uno diseñado para responder una pregunta distinta:

- El clustering jerárquico pregunta si los datos separan espontáneamente bancos de tech financiero.
- El PCA pregunta cómo se posicionan ambos grupos en el espacio riesgo-rendimiento y si esa posición cambia con el ciclo.
- El árbol de decisión pregunta qué variables determinan tener una rentabilidad ajustada al riesgo superior.
- El test de Mann-Whitney pregunta si las diferencias observadas son estadísticamente significativas o pueden ser producto del azar.

El periodo analizado incluye tres fases económicas claramente diferenciadas que permiten testar cómo responde cada grupo ante entornos distintos: los tipos de interés muy bajos (2015–2019), el shock del COVID-19 (2020–2021) y el ciclo de subida de tipos iniciado en 2022. Esta segmentación no es arbitraria, está justificada en el anteproyecto con base en la literatura financiera reciente y condiciona el diseño de todos los modelos aplicados.

2. Marco teórico y justificación metodológica

Antes de aplicar cualquier modelo, es necesario justificar por qué se han elegido estas técnicas y no otras. El objetivo no es usar los métodos más complejos disponibles, sino los más adecuados para la naturaleza de los datos y la pregunta de investigación.

2.1 Naturaleza de los datos y condicionantes metodológicos

El dataset de entrada de este análisis es DATOS_TFG_LIMPIO.xlsx, el output directo de la Ingeniería del Dato. Con diez empresas y 120 meses por empresa, se trata de un dataset de series temporales panel con muestra reducida. Esto descarta modelos que requieren grandes volúmenes de datos (como redes neuronales o XGBoost) y favorece técnicas interpretables que funcionen bien con pocos puntos en la dimensión de empresas.

Además, la pregunta de investigación es comparativa, no predictiva. No se busca predecir precios futuros, sino entender si los perfiles de riesgo-rentabilidad de los dos grupos son distintos y cómo evolucionan. Eso orienta la elección hacia modelos de agrupación, reducción de dimensionalidad y contraste estadístico.

2.2 Justificación de cada modelo

Clustering Jerárquico

El clustering jerárquico (Hastie, Tibshirani y Friedman, 2009) es una técnica de aprendizaje **no supervisado** que agrupa observaciones por similitud sin utilizar etiquetas previas. Se aplica el **método de Ward** como criterio de enlace, que en cada paso fusiona los clusters minimizando el incremento de varianza intra-cluster.

Se elige frente a alternativas como K-Means por dos motivos concretos: con diez empresas, el dendrograma resultante es completamente interpretable de forma visual; y no requiere especificar el número de clusters a priori, lo que permite que la estructura emerja de los propios datos sin imponer supuestos. La métrica de evaluación es el Silhouette Score (Rousseeuw, 1987), que mide la cohesión interna y la separación entre clusters en un rango de -1 a 1.

Análisis de Componentes Principales (PCA)

El PCA (Pearson, 1901; Hotelling, 1933) es una técnica de reducción de dimensionalidad **no supervisada** que transforma las variables originales en combinaciones lineales ortogonales ordenadas de mayor a menor varianza explicada. Su función aquí es complementar el clustering: mientras el clustering agrupa las diez empresas por su perfil agregado, el PCA proyecta las 1.200 observaciones mensuales en un plano bidimensional, permitiendo ver la distribución completa de los datos.

Los dos primeros componentes principales capturan el 74.3% de la varianza total del dataset, lo que valida que las cinco métricas financieras pueden resumirse razonablemente en dos dimensiones sin perder demasiada información.

Árbol de Decisión

El árbol de decisión (Breiman et al., 1984) es un algoritmo de aprendizaje **supervisado** que particiona recursivamente el espacio de variables maximizando la pureza de las clases en cada nodo mediante el criterio Gini. Su ventaja principal para este trabajo es la **interpretabilidad directa**: el árbol puede visualizarse y explicarse sin necesidad de conocimientos matemáticos avanzados.

La variable objetivo es binaria: si el Sharpe ratio de una empresa en un mes dado está por encima o por debajo de la mediana del mercado ese mes. Se utiliza un **split temporal** — entrenamiento con los dos primeros subperiodos (2015–2021) y test en el tercero (2022–2024) — para respetar la naturaleza temporal de los datos y evitar el data leakage que produciría un split aleatorio.

Es importante señalar de antemano que en series financieras mensuales es esperable que la capacidad predictiva de cualquier modelo sea limitada. Esto es coherente con la **hipótesis de mercado eficiente en su forma débil** (Fama, 1970): los precios reflejan toda la información histórica disponible, lo que dificulta obtener ventajas predictivas sistemáticas a partir de variables pasadas. El valor de este modelo reside en el análisis de importancia de variables, no en su uso predictivo.

Test de Mann-Whitney

El test de Mann-Whitney (1947) es la versión no paramétrica del t-test y no asume normalidad en la distribución de los datos, condición especialmente relevante en series financieras, que frecuentemente presentan asimetría y colas pesadas. Se aplica para cada métrica clave y cada subperiodo económico con un umbral de significancia $\alpha = 0.05$, respondiendo directamente las seis preguntas de investigación planteadas en el anteproyecto.

3. Modelo No Supervisado I: Clustering Jerárquico

3.1 Diseño y aplicación

Se aplica clustering jerárquico sobre el perfil medio de cada empresa en cada uno de los tres subperiodos económicos. Las variables utilizadas son rentabilidad mensual media, volatilidad media, Sharpe ratio medio, drawdown medio y beta media. Antes de calcular las distancias, todas las variables se normalizan con StandardScaler para evitar que diferencias de escala distorsionen los resultados.

El algoritmo no recibe la etiqueta banco/tech en ningún momento. Agrupa exclusivamente por similitud de métricas financieras. El resultado de cada dendrograma se puede contrastar con la clasificación real para evaluar si los datos confirman o contradicen la distinción banco/tech.

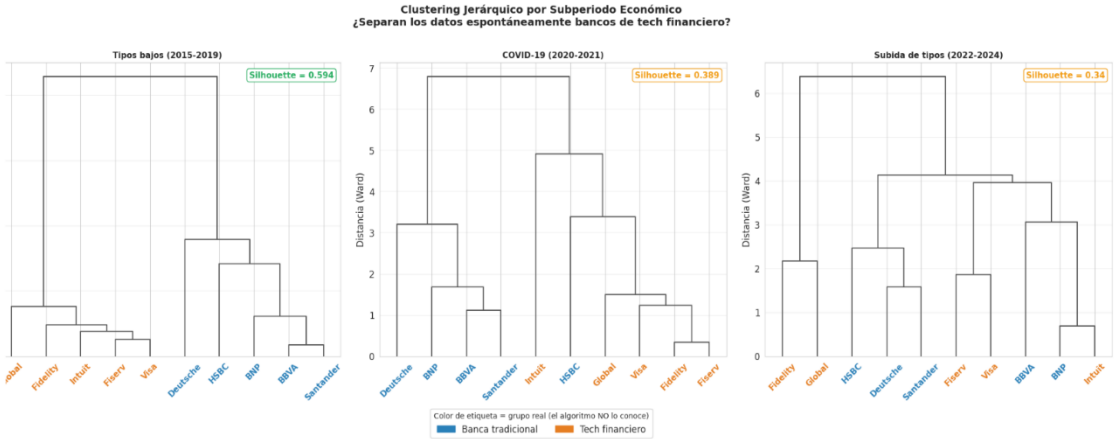

3.2 Resultados

Subperiodo	Silhouette Score	Interpretación	¿Separa bien?
Tipos bajos (2015–2019)	0.594	Separación fuerte	Sí — perfecta
COVID-19 (2020–2021)	0.389	Separación moderada	Parcial — HSBC migra
Subida de tipos (2022–2024)	0.340	Separación débil	No — 3 techs con bancos

3.3 Interpretación por subperiodo

Tipos bajos (2015–2019) — Silhouette Score: 0.594

Este es el resultado más claro de los tres. El algoritmo, sin conocer las etiquetas, coloca los cinco bancos en un cluster y las cinco empresas tech en otro de forma completamente separada. Un Silhouette Score de 0.594 indica que los perfiles de riesgo-rentabilidad de ambos grupos son estructuralmente distintos en esta fase.

La explicación financiera es coherente con la literatura. En un entorno de tipos bajos y abundante liquidez, las empresas de tech financiero se beneficiaron de unas condiciones muy favorables para su modelo de negocio: financiación barata, apetito inversor por el crecimiento y aceleración de la digitalización. Eso se tradujo en perfiles claramente diferenciados de los bancos, que en ese mismo entorno vieron comprimidos sus márgenes de intermediación (Bollaert, 2021; Beck, 2021).

COVID-19 (2020–2021) — Silhouette Score: 0.389

La separación se debilita. El caso más llamativo es HSBC, que el algoritmo desvincula del cluster bancario y agrupa con las techs. El Silhouette Score cae a 0.389, indicando que los perfiles convergen pero no llegan a mezclarse completamente.

El shock del COVID-19 fue tan intenso y afectó de forma tan diferente a cada entidad — independientemente de su categoría — que difuminó parcialmente las diferencias estructurales entre grupos. HSBC, con una exposición geográfica concentrada en Asia, se comportó durante la pandemia de forma más parecida a las techs que al resto de bancos europeos.

Subida de tipos (2022–2024) — Silhouette Score: 0.340

La separación por categorías se rompe casi por completo. Fiserv, Intuit y Visa se agrupan con los bancos; solo Fidelity y Global Payments quedan en un cluster separado. Este resultado es importante porque no significa que todas las empresas sean iguales, sino que en este entorno el tipo de entidad deja de ser el factor determinante del perfil financiero.

La subida de tipos benefició estructuralmente a los bancos al ampliar sus márgenes de intermediación, mientras que penalizó a las techs cuyas valoraciones dependían de expectativas de crecimiento futuro descontadas a tipos más altos. Las tres techs que migran al cluster bancario (Fiserv, Intuit y Visa) son precisamente las más maduras y con modelos de negocio más consolidados — no startups de alto crecimiento.

3.4 Conclusión del clustering

La distinción banco/tech es financieramente relevante pero dependiente del ciclo económico. Es máxima en entornos de tipos bajos favorables al crecimiento tecnológico, se modera ante shocks sistémicos como el COVID-19, y se diluye cuando el entorno macroeconómico cambia de forma estructural. Este resultado anticipa la conclusión central del trabajo y da soporte empírico a la hipótesis de que el ciclo económico es la variable moderadora clave.

4. Modelo No Supervisado II: Análisis de Componentes Principales (PCA)

4.1 Diseño y aplicación

Mientras el clustering trabaja con los perfiles medios de las diez empresas, el PCA proyecta las 1.200 observaciones mensuales completas en un espacio de dos dimensiones. Esto permite ver no solo dónde se sitúan los grupos en promedio, sino también cómo se distribuyen sus observaciones individuales y cuánto se solapan.

Se aplica sobre las mismas cinco variables que el clustering, normalizadas con StandardScaler. El número de componentes se fija en dos para poder visualizar el resultado en un plano bidimensional.

4.2 Interpretación de los componentes principales

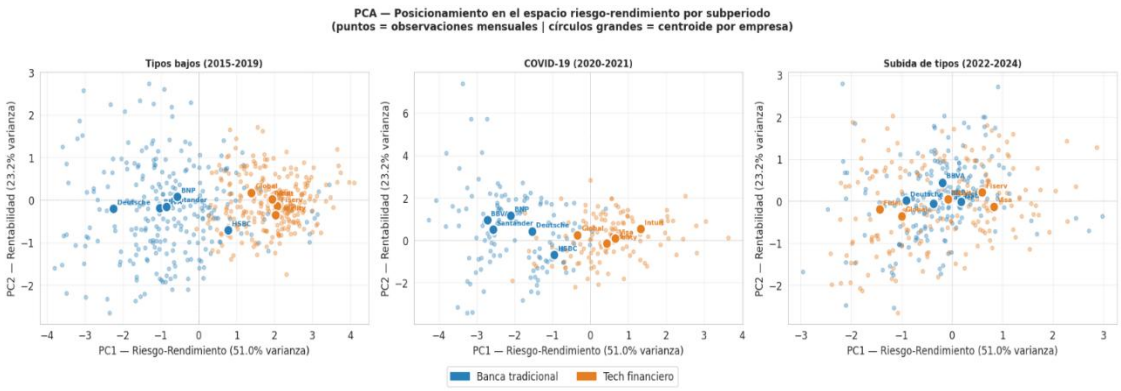

Componente	Varianza explicada	Variables dominantes	Interpretación financiera
PC1	51.0%	Drawdown (+0.525), Sharpe (+0.454), Volatilidad (-0.516), Beta (-0.490)	Eje riesgo-rendimiento ajustado
PC2	23.2%	Rentabilidad mensual (+0.815)	Eje de rentabilidad absoluta
Total	74.3%	—	Varianza capturada con 2 dimensiones

El primer componente (PC1) captura el **51% de la varianza total** y puede interpretarse como un eje de riesgo-rendimiento ajustado: valores altos de PC1 indican empresas con mayor Sharpe, menor drawdown, menor volatilidad y menor beta. Es decir, empresas con mejor perfil financiero en términos de rentabilidad ajustada al riesgo. El segundo componente (PC2) está casi exclusivamente determinado por la rentabilidad mensual

bruta (+0.815) y representa la dimensión de rentabilidad absoluta, independiente del riesgo asumido.

4.3 Resultados por subperiodo

Tipos bajos (2015–2019)

Los centroides de las empresas tech aparecen desplazados hacia la derecha en el eje PC1 respecto a los bancos. Dado que valores altos de PC1 indican mejor perfil de riesgo-rendimiento ajustado, este desplazamiento confirma en términos visuales lo que el clustering y el Mann-Whitney demuestran estadísticamente: en esta fase las techs ocupan una posición más favorable. La separación es visible aunque los puntos se solapan, lo que refleja la variabilidad mensual dentro de cada grupo.

COVID-19 (2020–2021)

Los centroides se aproximan en el eje PC1. La separación se reduce de forma visible respecto a la fase anterior. HSBC aparece claramente desplazado hacia el espacio tech en el plano, lo que replica de forma visual la migración de cluster detectada en el dendrograma. El eje PC2 muestra mayor dispersión vertical en esta fase — la rentabilidad absoluta fue más volátil e impredecible durante la pandemia para ambos grupos, lo que es consistente con el contexto de mercado.

Subida de tipos (2022–2024)

Los centroides convergen casi completamente en el centro del plano. Fiserv, Visa e Intuit se posicionan prácticamente encima de los centroides bancarios. La distinción banco/tech deja de traducirse en una separación clara en el espacio riesgo-rendimiento — los perfiles financieros se homogenizan. Este es el resultado visual más contundente del análisis: en el tercer subperiodo no se distinguen dos nubes de puntos separadas, sino una única nube donde ambos grupos se mezclan.

4.4 Conclusión del PCA

Los tres subperiodos muestran una tendencia progresiva de convergencia: la ventaja posicional del tech financiero en el eje de riesgo-rendimiento ajustado es máxima en tipos bajos, se modera durante el COVID y prácticamente desaparece en la subida de tipos. Este resultado es coherente con los hallazgos del clustering y refuerza la conclusión central: la ventaja comparativa de cada grupo depende fundamentalmente del ciclo económico, no de características intrínsecas e invariantes de cada tipo de entidad.

5. Modelo Supervisado: Árbol de Decisión

5.1 Diseño y aplicación

Se entrena un árbol de decisión para predecir si una empresa tiene un Sharpe ratio superior a la mediana del mercado en un mes dado. Las features del modelo son: volatilidad mensual, beta, tipo de entidad (banco/tech codificado como 0/1), subperiodo económico, rentabilidad mensual y drawdown. El modelo se entrena sobre el dataset limpio generado en la Ingeniería del Dato (DATOS_TFG_LIMPIO.xlsx).

Se aplica un **split temporal**: entrenamiento con los subperiodos 0 y 1 (2015–2021, 730 observaciones) y test con el subperiodo 2 (2022–2024, 360 observaciones). Este enfoque es metodológicamente más correcto que un split aleatorio para series temporales, ya que evita que el modelo entrene con información futura.

Los hiperparámetros se fijan en max_depth = 4 y min_samples_leaf = 15 para limitar la complejidad del árbol y evitar el sobreajuste, manteniendo al mismo tiempo la interpretabilidad visual del resultado.

5.2 Métricas de evaluación

Métrica	Valor	Referencia	Interpretación
Accuracy	0.564	0.5 (aleatorio)	Acierta el 56.4% de los casos
F1-Score	0.425	0.0–1.0	Equilibrio entre precisión y recall
AUC-ROC	0.530	0.5 (aleatorio)	Capacidad discriminante limitada

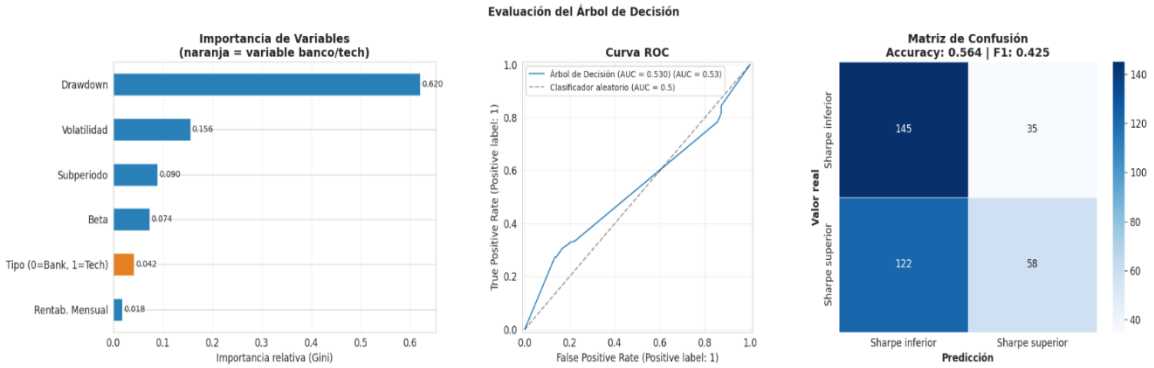

Las métricas son modestas y se sitúan cerca del umbral de un clasificador aleatorio. Esto no es una sorpresa ni un error metodológico. Es un resultado esperado y consistente con la hipótesis de mercado eficiente en su forma débil (Fama, 1970): los precios de los activos reflejan toda la información histórica disponible, lo que hace difícil predecir sistemáticamente el comportamiento relativo de activos financieros a partir de variables pasadas. Décadas de investigación financiera han documentado este fenómeno.

El valor de este modelo no reside en su capacidad predictiva, sino en el análisis de importancia de variables. Independientemente de que el modelo prediga bien o mal, el feature importance revela qué factores tienen mayor peso en la distinción entre perfiles de Sharpe superior e inferior — y eso sí es un hallazgo financieramente relevante.

5.3 Feature Importance — el hallazgo principal

Variable	Importancia relativa	Posición
Drawdown	0.620	1ª
Volatilidad	0.156	2ª
Subperiodo	0.090	3ª
Beta	0.074	4ª
Tipo (banco/tech)	0.042	5ª
Rentabilidad mensual	0.018	6ª

El **drawdown** es con diferencia la variable más determinante, con una importancia relativa de 0.620. Las empresas que controlan mejor sus caídas máximas desde máximos históricos son sistemáticamente las que obtienen un Sharpe superior a la mediana del mercado.

La **volatilidad** ocupa la segunda posición (0.156), seguida del **subperiodo económico** (0.090). La variable **tipo de entidad — banco o tech —** aparece en quinta posición con una importancia de apenas 0.042.

Este resultado tiene una lectura financiera clara: lo que determina si una empresa tiene una buena rentabilidad ajustada al riesgo no es principalmente su categoría como banco o tech, sino su capacidad para gestionar el riesgo a la baja. Una empresa — sea banco o fintech — que controla sus drawdowns y mantiene baja volatilidad tiene sistemáticamente mejor Sharpe que otra de la misma categoría que no lo hace.

Este hallazgo está en línea con Bollaert (2021), que documenta que las empresas de tech financiero presentan drawdowns más profundos que la banca tradicional. Los datos aquí confirman que esa mayor exposición a caídas máximas es precisamente el factor que más penaliza su Sharpe en términos comparativos.

6. Análisis estadístico: Test de Mann-Whitney por subperiodo

6.1 Diseño y aplicación

Para que las diferencias observadas entre grupos tengan valor científico, deben superar una prueba de significancia estadística. El test de Mann-Whitney (1947) es la versión no paramétrica del t-test y no asume normalidad en la distribución — condición especialmente relevante en series financieras, que frecuentemente presentan asimetría y colas pesadas.

Se aplica para cada una de las cinco métricas clave (rentabilidad mensual, volatilidad, Sharpe ratio, drawdown y beta) en cada uno de los tres subperiodos económicos, lo que genera 15 contrastes en total. El umbral de significancia utilizado es α = 0.05.

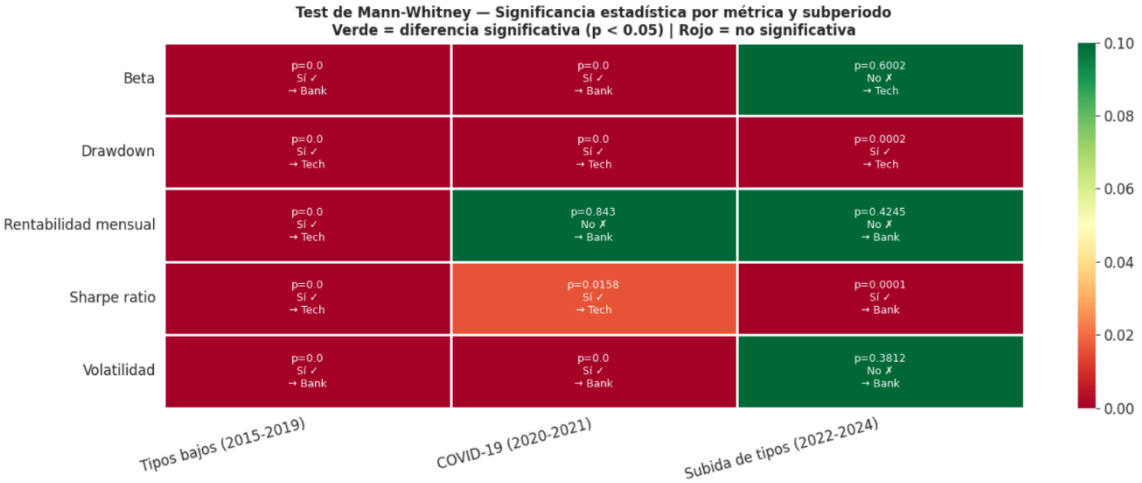

6.2 Resultados

Fase de tipos bajos (2015–2019)

Métrica	Media Bank	Media Tech	p-valor	Significativo	Gana
Rentabilidad mensual	-0.0040	0.0201	< 0.001	Sí	Tech
Volatilidad	0.0791	0.0511	< 0.001	Sí	Bank (menor)
Sharpe ratio	-0.065	0.417	< 0.001	Sí	Tech
Drawdown	-0.283	-0.025	< 0.001	Sí	Tech (menor caída)
Beta	1.344	0.432	< 0.001	Sí	Bank (menor)

Las diferencias son estadísticamente significativas en las cinco métricas. El tech financiero presenta mayor rentabilidad mensual, mejor Sharpe y menor caída máxima.

Los bancos, por su parte, muestran menor volatilidad y menor beta — son más estables y menos sensibles al mercado, pero a costa de una rentabilidad ajustada al riesgo claramente inferior.

Este resultado confirma la tesis de Beck (2021) y Bollaert (2021): en entornos de tipos bajos y abundante liquidez, las empresas de tech financiero presentan una relación rentabilidad-riesgo superior a la banca tradicional.

Fase COVID-19 (2020–2021)

Métrica	Media Bank	Media Tech	p-valor	Significativo	Gana
Rentabilidad mensual	0.0105	0.0073	0.843	No	—
Volatilidad	0.1255	0.0834	< 0.001	Sí	Bank (menor)
Sharpe ratio	0.033	0.199	0.016	Sí	Tech
Drawdown	-0.528	-0.087	< 0.001	Sí	Tech (menor caída)
Beta	1.464	0.861	< 0.001	Sí	Bank (menor)

El panorama cambia. La rentabilidad deja de ser significativamente distinta entre grupos ($p = 0.843$) — el shock del COVID igualó los retornos medios. Sin embargo, el tech financiero sigue teniendo mejor Sharpe ($p = 0.016$) y menor drawdown ($p < 0.001$). Los bancos sufrieron caídas máximas mucho más profundas (-52.8% frente a -8.7%), lo que refleja la mayor exposición de la banca tradicional al riesgo de crédito durante la crisis.

Fase de subida de tipos (2022–2024)

Métrica	Media Bank	Media Tech	p-valor	Significativo	Gana
Rentabilidad mensual	0.0140	0.0064	0.425	No	—
Volatilidad	0.0854	0.0824	0.381	No	—
Sharpe ratio	0.168	0.065	< 0.001	Sí	Bank
Drawdown	-0.343	-0.266	< 0.001	Sí	Tech (menor caída)
Beta	0.990	1.007	0.600	No	—

El giro es estadísticamente claro. Los bancos obtienen un **Sharpe ratio significativamente superior** ($p < 0.001$), con una diferencia de -0.103 puntos a favor de la banca. La rentabilidad y la volatilidad dejan de diferir significativamente entre grupos — los perfiles convergen. El tech financiero mantiene menor drawdown ($p < 0.001$), pero en el indicador clave de rentabilidad ajustada al riesgo, los bancos recuperan la ventaja.

Este resultado confirma lo que anticipaban IMF (2023) y Beck (2021): la subida de tipos beneficia estructuralmente a la banca tradicional al ampliar sus márgenes de

intermediación, mientras que penaliza a las techs, cuyas valoraciones dependen en mayor medida de expectativas de crecimiento futuro descontadas a tipos más altos.

6.3 Resumen estadístico global

De los 15 contrastes realizados, 11 resultan estadísticamente significativos ($p < 0.05$). Los 4 no significativos corresponden a la rentabilidad en COVID y subida de tipos, la volatilidad en subida de tipos y la beta en subida de tipos — todos casos en que los perfiles de ambos grupos convergen, lo que ya anticipa el clustering.

7. Conclusiones del Análisis del Dato

7.1 Conclusión central

Respuesta a la pregunta de investigación
Las empresas de tech financiero ofrecieron una mejor relación rentabilidad–riesgo que la banca tradicional durante el periodo de tipos bajos y expansión (2015–2021). Sin embargo, esa ventaja se invirtió de forma estadísticamente significativa en el ciclo de subida de tipos (2022–2024), cuando la banca tradicional recuperó su superioridad en rentabilidad ajustada al riesgo. No existe un ganador universal.

La ventaja comparativa de cada grupo depende fundamentalmente del entorno macroeconómico. Esta conclusión está respaldada por los cuatro niveles de análisis de forma coherente y consistente, y confirma la hipótesis central del anteproyecto y la tesis de Beck (2021) e IMF (2023): el ciclo económico es la variable moderadora clave en la comparativa banco-tech.

7.2 Hallazgos por modelo

Clustering jerárquico: La separación estructural entre perfiles existe y es fuerte en tipos bajos (Silhouette Score: 0.594), se modera en COVID (0.389) y se debilita significativamente en subida de tipos (0.340). En el tercer subperiodo, tres de las cinco techs — Fiserv, Intuit y Visa — se comportan de forma indistinguible de los bancos.

PCA: La tendencia de convergencia es visualmente clara en la evolución de los centroides por subperiodo. En tipos bajos hay separación espacial en el eje riesgo-rendimiento; en subida de tipos los centroides de ambos grupos convergen en el centro del plano. Entre ambos componentes se captura el 74.3% de la varianza total del dataset.

Árbol de decisión: El factor más determinante para obtener un Sharpe superior no es el tipo de entidad (importancia: 0.042), sino el drawdown (0.620) y la volatilidad (0.156). Lo que diferencia a las empresas con mejor rentabilidad ajustada al riesgo es su capacidad de controlar las caídas máximas, independientemente de si son bancos o techs.

Test de Mann-Whitney: 11 de 15 contrastes son estadísticamente significativos. En tipos bajos, todas las diferencias son significativas. En COVID, la rentabilidad pierde significancia pero el Sharpe y el drawdown siguen favoreciendo al tech. En subida de tipos, el Sharpe se invierte a favor de la banca ($p < 0.001$) y tres de las cinco métricas convergen sin diferencias significativas.

7.3 Resumen de métricas de evaluación

Modelo	Métrica	Valor
Clustering Jerárquico	Silhouette Score (Tipos bajos)	0.594
Clustering Jerárquico	Silhouette Score (COVID-19)	0.389
Clustering Jerárquico	Silhouette Score (Subida tipos)	0.340
PCA	Varianza explicada (2 componentes)	74.3%
Árbol de Decisión	Accuracy	0.564
Árbol de Decisión	F1-Score	0.425
Árbol de Decisión	AUC-ROC	0.530

8. Referencias bibliográficas

Beck, T., Frost, J., Gambacorta, L., & Shin, H. (2021). Financial innovation and its impact on estabilidad y crecimiento. *Journal of Financial Stability*, 53.

Bollaert, H., Lopez-de-Silanes, F., & Schwienbacher, A. (2021). Fintech y valoración de mercado. *Journal of Corporate Finance*, 66.

Breiman, L., Friedman, J., Olshen, R., & Stone, C. (1984). Classification and Regression Trees. Wadsworth.

Fama, E.F. (1970). Efficient capital markets: A review of theory and empirical work. *Journal of Finance*, 25(2), 383–417.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning. Springer.

Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24(6), 417–441.

International Monetary Fund (2023). Fintech and financial stability: Policy implications. *IMF Working Paper*.

Mann, H.B., & Whitney, D.R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *Annals of Mathematical Statistics*, 18(1), 50–60.

Pearson, K. (1901). On lines and planes of closest fit to systems of points in space. *Philosophical Magazine*, 2(11), 559–572.

Rousseeuw, P.J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.